Diplomado en Ciencia de Datos y Análisis Avanzado

UTN FRBA — Centro de e-Learning

Detección de fallas en sensores IoT industriales

Proyecto Final Integrador — Informe Final

Autores

Juan Marcelo Saumell

Axel Carcia

Juan Ignacio Figueiras

Luis Ignacio Alaniz Bellotti

Santino Martins

Octubre 2026

1. Resumen ejecutivo

En manufactura, una parada no planificada cuesta entre USD 36,000 y 2.3 millones por hora según el sector (Siemens, 2024). Este proyecto construye un modelo que, a partir de lecturas de temperatura, velocidad, torque y desgaste de herramienta, identifica las máquinas en riesgo de falla para intervenir antes de que se detengan.

Se compararon cuatro enfoques (Regresión Logística, Random Forest, XGBoost e Isolation Forest). El modelo elegido, un Random Forest, se evaluó sobre datos que no se usaron para entrenarlo:

- **Detecta 85 de cada 100 fallas** (58 de 68 en el conjunto de prueba).
- **3 de cada 4 alertas son correctas** (19 falsas alarmas sobre 2,000 registros).
- **Reduce el costo asociado a fallas en un 74%** frente al mantenimiento reactivo, suponiendo que una falla no detectada cuesta 10 veces más que una inspección. El ahorro va de 62% a 87% según esa relación de costos.

Recomendación: implementar el sistema como piloto de alertas en una línea con datos reales, manteniendo las inspecciones programadas como respaldo.

2. Definición del problema y relevancia

Las paradas no planificadas son uno de los mayores costos ocultos de la industria: le cuestan a las 500 mayores empresas del mundo el 11% de sus ingresos, unos USD 1.4 billones por año (Siemens, 2024). Pasar de un mantenimiento reactivo (reparar cuando algo se rompe) a uno preventivo basado en el riesgo permite planificar las intervenciones y evitar paradas.

Objetivo medible: Desarrollar un modelo que identifique estados operativos de alto riesgo de falla, maximizando el F1-Score sobre la clase falla y superando a un modelo base (baseline) de regresión logística.

Hipótesis: Las variables de proceso contienen patrones que distinguen los estados previos a una falla, y un modelo supervisado puede capturarlos mejor que un modelo lineal simple.

Benchmark de negocio: El mantenimiento reactivo, en el que todas las fallas ocurren sin aviso.

Restricciones: Dataset sintético, sin información temporal (el modelo estima el riesgo del estado actual, no cuándo ocurrirá la falla) y con fuerte desbalance de clases (3.4% de fallas).

3. Datos y metodología

3.1 Fuente y calidad de los datos

AI4I 2020 Predictive Maintenance Dataset (UCI Machine Learning Repository, DOI 10.24432/C5HS5C; Matzka, 2020), modelado sobre una fresadora real. Licencia CC BY 4.0. 10,000 registros y 14 columnas, sin valores faltantes. 339 registros (3.4%) son fallas.

Variable	Unidad	Descripción
Type	—	Calidad del producto: L (50%), M (30%), H (20%)
Air / Process temperature	K	Temperatura ambiente (~300 K) y de proceso (~310 K)
Rotational speed	rpm	Velocidad rotacional (~1539 rpm, SD=179)
Torque	Nm	Torque (~40 Nm, SD=10)
Tool wear	min	Desgaste acumulado de herramienta
Machine failure	—	Variable objetivo: 0 = normal, 1 = falla
TWF, HDF, PWF, OSF, RNF	—	Modos de falla: desgaste, calor, potencia, sobrecarga, aleatoria

Conclusiones del análisis exploratorio:

- Sin nulos ni duplicados. Las temperaturas están muy correlacionadas ($r \approx 0.88$).
- Hay valores atípicos en Rotational speed (4.2%) y Torque (0.7%). Son físicamente posibles y concentran fallas, por lo que se conservaron.
- Se detectaron inconsistencias menores de etiquetado: 9 fallas sin modo asociado y 18 registros con falla aleatoria (RNF) no reflejados en el objetivo. Se mantuvo la variable objetivo sin cambios y se documentó como limitación.
- La tasa de falla varía según el tipo de producto: High (H) presenta la mayor incidencia (aproximadamente 4%), seguido de Medium (M) con 3.5% y Low (L) con 3.3%. Si bien la diferencia es moderada, resulta consistente con la hipótesis de que piezas de mayor calidad operan bajo condiciones más exigentes.
- Los diagramas de caja revelan separación visible entre estados normales y de falla en las variables Torque y Rotational speed: las fallas se concentran en torques elevados (mediana ~55 Nm vs ~40 Nm en operación normal) y velocidades rotacionales bajas (mediana ~1.350 rpm vs ~1.500 rpm). Esta separación anticipa la utilidad predictiva de la variable derivada Power.
- La distribución de Air temperature y Process temperature es aproximadamente normal y simétrica, con diferencias mínimas entre clases, lo que sugiere que su aporte

predictivo individual es limitado, aunque Temp_delta (la diferencia entre ambas) captura el efecto térmico relevante.

3.2 Preparación de los datos

- **Identificadores:** se descartaron UID y Product ID por no tener valor predictivo.
- **Type:** codificación ordinal (L<M<H). Se comparó contra one-hot en validación cruzada y empataron (F1 0.233 vs 0.234), por lo que se eligió la más simple.
- **Ingeniería de variables:** Temp_delta (diferencia de temperaturas), Power (potencia = torque × velocidad angular) y Strain (desgaste × torque).
- **Partición:** 80% entrenamiento y 20% prueba, estratificada. La prueba quedó aislada hasta la evaluación final; toda selección se hizo con validación cruzada de 5 folds sobre entrenamiento.

3.3 Metodología CRISP-DM

Fase	Dónde está en el proyecto
1. Comprensión del negocio	Problema, KPI y benchmark de mantenimiento reactivo (sección 2)
2. Comprensión de los datos	Análisis exploratorio, calidad y consistencia del objetivo (3.1)
3. Preparación de los datos	Limpieza, codificación y nuevas variables (3.2)
4. Modelado	Baseline, comparación de algoritmos y manejo del desbalance (4.1)
5. Evaluación	Umbral por costos, prueba final e interpretación (4.2 a 5)
6. Despliegue (propuesta)	Piloto de alertas por máquina (sección 7)

4. Modelado y evaluación

4.1 Comparación de algoritmos

Se probaron Regresión Logística, Random Forest y XGBoost, cada uno con dos conjuntos de variables (base y con variables de dominio) y dos formas de tratar el desbalance (pesos de clase y SMOTE). Los hiperparámetros se buscaron con 20 combinaciones aleatorias por configuración. Como referencia no supervisada se evaluó Isolation Forest. La métrica de selección fue PR-AUC, adecuada cuando la clase de interés es rara y que no depende del umbral.

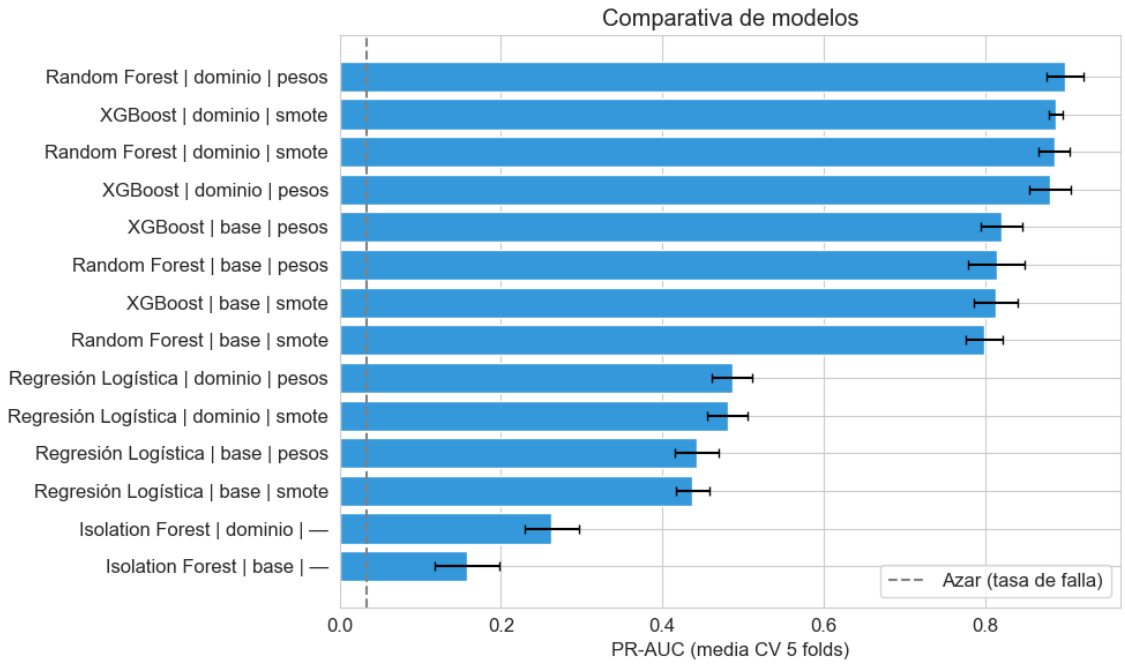


Figura 1. PR-AUC por configuración (media y desvío en validación cruzada de 5 folds).

Los cuatro mejores modelos quedaron dentro de la variación entre folds, por lo que se reevaluaron con validación cruzada repetida (5 folds × 3 repeticiones):

Modelo	Variables	Desbalance	PR-AUC	F1	Recall
Random Forest	**Dominio**	**Pesos**	**0.894 ± 0.030**	**0.858**	**78.5%**
XGBoost	Dominio	SMOTE	0.877 ± 0.034	0.551	88.9%
Random Forest	Dominio	SMOTE	0.874 ± 0.040	0.655	87.5%
XGBoost	Dominio	Pesos	0.866 ± 0.056	0.617	89.0%
Reg. Logística (baseline)	Base	Pesos	0.442 ± 0.027	0.233	80.4%

Selección: Se eligió Random Forest con variables de dominio y pesos de clase: fue el primero en las dos evaluaciones y es el más simple de operar, ya que no genera datos sintéticos. Su ventaja sobre XGBoost no es estadísticamente concluyente. Las variables de dominio fueron el factor decisivo: subieron la PR-AUC unos 8 puntos. Isolation Forest (PR-AUC 0.26) confirmó que, con fallas etiquetadas, el enfoque supervisado es muy superior.

4.2 Umbral de decisión según costos

El modelo no responde "falla sí o no": entrega una probabilidad de falla (por ejemplo, 62%). Hay que decidir a partir de qué probabilidad se envía a un técnico a revisar la máquina; ese valor de corte es el umbral. Con un umbral de 0.38, toda máquina con 38% o más de probabilidad genera una alerta.

Con un umbral bajo se escapan pocas fallas, pero hay muchas falsas alarmas; con uno alto, ocurre lo contrario. Para elegirlo se compararon costos: cada alerta implica una

inspección (costo 1) y cada falla que no se detecta provoca una parada no planificada, mucho más cara. El dataset no incluye costos y no se encontró una relación publicada y verificable, por lo que se probaron cuatro supuestos: una falla no detectada cuesta 5, 10, 20 o 50 inspecciones. El caso central es 10.

Ejemplo con el supuesto 10:1 sobre los datos de entrenamiento (271 fallas):

Umbral	Fallas detectadas	No detectadas	Falsas alarmas	Costo total
0.10 (muy sensible)	257	14	423	14×10 + 680 alertas = 820
0.38 (elegido)	**227**	**44**	**39**	**44×10 + 266 alertas = 706**
0.50 (por defecto)	215	56	13	56×10 + 228 alertas = 788

El umbral 0.38 es el de menor costo total. Sin modelo (mantenimiento reactivo) las 271 fallas ocurren sin aviso y cuestan 271×10 = 2,710; con el modelo el costo es 706, un 74% menos. Ese es el ahorro que se informa. El umbral se eligió solo con datos de entrenamiento, para que la prueba final siga siendo independiente.

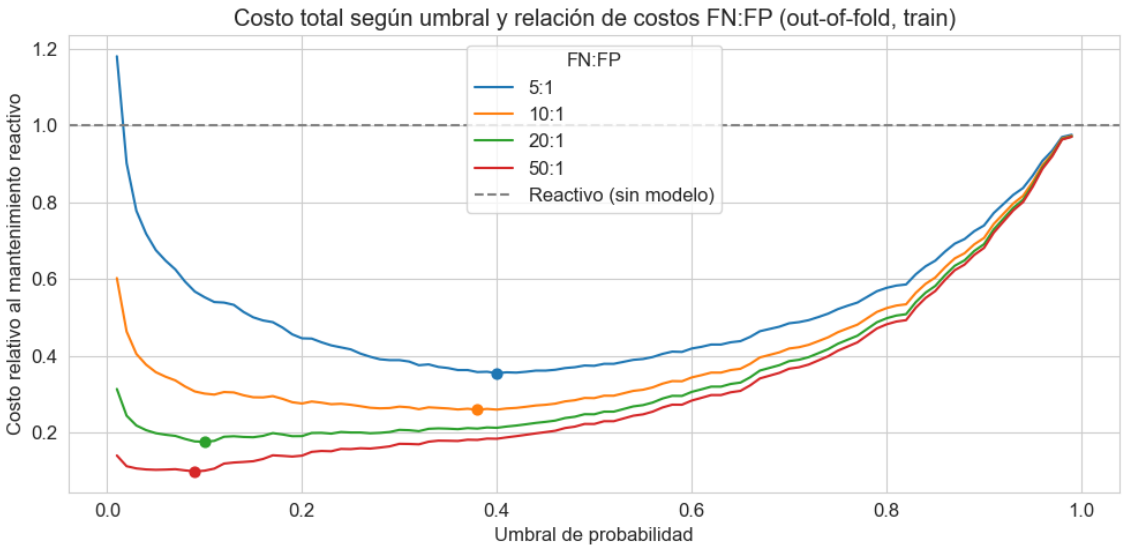


Figura 2. Costo total relativo al mantenimiento reactivo según el umbral (entrenamiento).

4.3 Resultados en el conjunto de prueba

Con el umbral del escenario central (0.38), el modelo se evaluó una sola vez sobre los 2,000 registros de prueba:

Métrica	Baseline (CV)	Modelo final (prueba)
PR-AUC	0.442	0.873
ROC-AUC	—	0.983
F1-Score	0.233	0.800
Precision	13.6%	75.3%
Recall	80.4%	85.3%

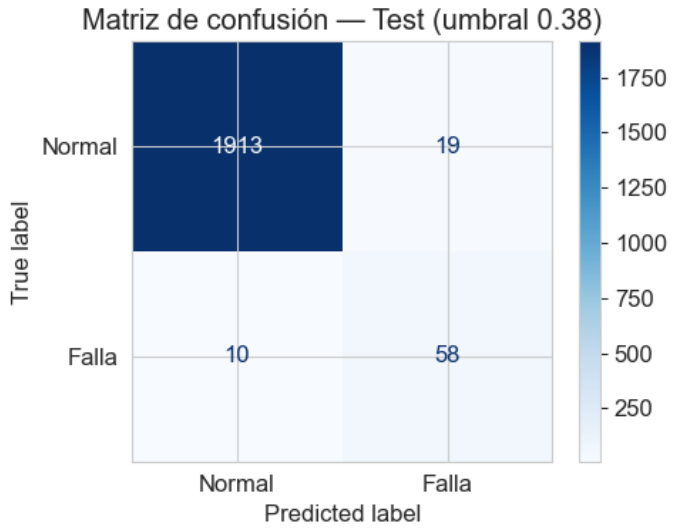


Figura 3. Matriz de confusión en prueba: 58 fallas detectadas, 10 no detectadas y 19 falsas alarmas.

La PR-AUC y el recall en prueba coinciden con la validación cruzada, lo que indica que el modelo no está sobreajustado. Respecto del baseline, el F1 pasa de 0.23 a 0.80.

5. Impacto en el negocio

El modelo reduce el costo asociado a fallas en todos los escenarios analizados:

Relación falla : inspección	Fallas detectadas	Falsas alarmas	Ahorro vs reactivo
5 : 1	57 de 68	16	62%
10 : 1 (central)	**58 de 68**	**19**	**74%**
20 : 1	63 de 68	116	80%
50 : 1	63 de 68	123	87%

Cuanto más cara es una parada, más conviene bajar el umbral: con relaciones de 20:1 o más se detectan 5 fallas adicionales a cambio de unas 100 inspecciones extra. Cada planta debe estimar su propia relación de costos para fijar el umbral.

Qué explica las fallas: Las variables más influyentes (importancia por permutación) se corresponden con los mecanismos de falla: la velocidad de rotación y la diferencia de temperatura explican las fallas por disipación de calor; la potencia, las fallas eléctricas; y el desgaste por torque junto con el tipo de producto, las sobrecargas. Esto permite explicar cada alerta al equipo de mantenimiento en términos operativos.

Riesgos y limitaciones:

- Datos sintéticos: el modelo aprende las reglas con que se generaron las fallas; debe validarse con datos reales antes de usarse en producción.
- Sin información temporal: el modelo indica riesgo actual, no con cuánta anticipación ocurrirá la falla.

- Las fallas aleatorias (RNF) no son predecibles por definición.
- Los costos son supuestos; el ahorro depende de la relación real de cada planta.
- Con 68 fallas en prueba, la precisión puede variar algunos puntos.
- El modelo de costos se corrigió durante el trabajo para incluir el costo de las alertas correctas; el umbral se eligió siempre con datos de entrenamiento.

Escalabilidad: El modelo se entrena en segundos y predice en milisegundos, por lo que puede aplicarse a muchas máquinas sin infraestructura especial.

6. Consideraciones éticas y de privacidad

AI4I 2020 es sintético y tiene licencia CC BY 4.0, que permite usarlo citando la fuente. No contiene datos personales, por lo que no aplica la Ley 25.326 de Protección de Datos Personales. En un despliegue real se identifican estos riesgos y mitigaciones:

- **Vigilancia laboral:** los datos de las máquinas pueden vincularse a operarios o turnos. Analizar por máquina y no por persona, e informar a los trabajadores.
- **Sesgo de automatización:** el modelo da apoyo y el técnico decide; no reemplaza los protocolos de seguridad.
- **Fallas no detectadas (15%):** mantener las inspecciones programadas como respaldo.
- **Generalización:** validar con datos reales antes de usarlo en producción.
- **Transparencia:** el umbral y las variables importantes quedan documentados.

7. Conclusiones y recomendaciones

- Es posible anticipar el 85% de las fallas con datos de sensores que ya existen en planta, con 3 de cada 4 alertas correctas.
- La clave del desempeño fueron las variables construidas con conocimiento del proceso (potencia, desgaste por torque y diferencia de temperatura), más que el algoritmo.
- El ahorro estimado frente al mantenimiento reactivo es del 74% en el escenario central y se mantiene por encima del 60% en todos los escenarios.

Próximos pasos sugeridos:

1. Piloto de 3 meses en una línea con datos reales, midiendo paradas evitadas y falsas alarmas.
2. Estimar con el área de mantenimiento la relación real de costos y ajustar el umbral.
3. Incorporar series de tiempo para anticipar cuándo ocurrirá la falla.

4. Reentrenar periódicamente y monitorear el desempeño del modelo.

Referencias

Matzka, S. (2020). Explainable Artificial Intelligence for Predictive Maintenance Applications. Third International Conference on Artificial Intelligence for Industries (AI4I).

UCI Machine Learning Repository. AI4I 2020 Predictive Maintenance Dataset. https://doi.org/10.24432/C5HS5C

Siemens (2024). The True Cost of Downtime 2024. Siemens AG / Senseye.

Código: notebook TP_Final_Anomalias_IoT.ipynb y README en el repositorio público https://github.com/Oddie12/DYSDD_UTN_Grupo34.